

Trabalho Final

Alexandre Novaes Dornelas
José Carlos Maria Júnior
Thiago Itamar Plum
Walter Alves Moreira Barbosa dos Santos
Ygor Silva Nascimento Coelho

Análise Exploratória de Dados

Preparação do ambiente e carregamento de bibliotecas

Esse passo é feito uma única vez para todo o script. Destaca-se que, a depender da instalação do usuário, pode ser necessária a instalação de pacotes adicionais. O comando a seguir “ativa” as funções do pacote.

```
library(readxl)
library(dplyr)      # Manipulação e transformação de dados
library(ggplot2)    # Visualização de dados
library(ggpubr)     # Gráficos estatísticos (ex: QQ-plots)
library(patchwork)  # Combinação de gráficos
library(naniar)     # Visualização de dados faltantes
library(visdat)     # Visualização estrutural da base
library(gtsummary)  # Tabelas descritivas formatadas
library(epiR)       # Intervalos de confiança e análises epidemiológicas
library(DescTools)  # Testes estatísticos adicionais
library(vcd)        # Associação entre variáveis categóricas
library(car)        # Para VIF (multicolinearidade)
library(olsrr)      # Para testes de pressupostos (Homocedasticidade)
```

Em seguida, carregamos a base de dados fornecida para realizar a Análise Exploratória de Dados. A função `read_excel()` lê o arquivo e o armazena na variável ‘dados’. Em seguida, iremos checar que o “tibble” foi carregado corretamente.

```
dados <- read_excel("Base_trabalho.xlsx")
dados
```

```
## # A tibble: 200 x 8
##   idade escolaridade reincidente filhos  sexo tempo_preso casado
##   <dbl> <chr>          <dbl>  <dbl> <dbl>    <dbl>  <dbl>
## 1    60 1          0      0      1      58      0
## 2    60 3          0      0      1      63      1
## 3    30 3          1      0      1      52      0
## 4    63 2          0      1      1      66      1
## 5    33 1          0      1      1      45      0
## 6    53 2          0      0      0      76      0
## 7    48 2          0      0      1      70      0
```

```
## 8      43 2              1      1      1              68      1
## 9      49 2              0      1      0              45      0
## 10     36 2              1      0      1              74      0
## # i 190 more rows
## # i 1 more variable: score_periculosidade <dbl>
```

A partir dessa etapa, considera-se a preparação do ambiente terminada.

Normalização dos Dados

Considerando as colunas que possuem dados numéricos, vamos realizar a padronização e normalização dos dados, convertendo as variáveis binárias para fatores com rótulos.

```
dados <- dados |>
  mutate(
    sexo = factor(x = sexo,
                  levels = c(0, 1),
                  labels = c("Masculino", "Feminino")),
    filhos = factor(x = filhos,
                   levels = c(0, 1),
                   labels = c("Não", "Sim")),
    escolaridade = factor(x = escolaridade,
                         levels = c(1, 2, 3),
                         labels = c("Fundamental", "Médio", "Superior")),
    casado = factor(x = casado,
                   levels = c(0, 1),
                   labels = c("Não", "Sim")),

    reincidente = factor(x = reincidente,
                       levels = c(0, 1),
                       labels = c("Não", "Sim"))
  )
```

Verificação do carregamento dos dados

Vamos proceder à verificação preliminar dos nomes das colunas, bem como à sumarização dos dados.

```
names(dados)
```

```
## [1] "idade"           "escolaridade"    "reincidente"
## [4] "filhos"          "sexo"            "tempo_preso"
## [7] "casado"          "score_periculosidade"
```

```
summary(dados)
```

```
##      idade      escolaridade reincidente filhos      sexo
## Min.   :18.00  Fundamental:93   Não:162   Não: 96  Masculino: 62
## 1st Qu.:34.00   Médio      :66   Sim: 38   Sim:104  Feminino :138
## Median :52.00  Superior   :41
```

```
## Mean      :50.91
## 3rd Qu.   :64.25
## Max.      :97.00
## tempo_preso  casado  score_periculosidade
## Min.       :37.00  Não:126  Min.       : 91.05
## 1st Qu.    :53.75  Sim: 74  1st Qu.   :155.70
## Median     :60.50           Median   :177.21
## Mean       :60.59           Mean      :174.52
## 3rd Qu.    :67.00           3rd Qu.   :191.12
## Max.       :88.00           Max.       :247.07
```

Questão 1:


Podemos afirmar que o score médio de periculosidade é superior a 170 pontos? Utilize um nível de significância de 5%. Caso a média seja significativamente maior que 170, apresente também o intervalo de confiança de 95% correspondente.

1. Análise Exploratória de Dados (EDA)

Primeiro, verifica-se a distribuição com um histograma.

```
# Histograma
hist(dados$score_periculosidade,
     main="Histograma do Score de Periculosidade",
     xlab="Score",
     col="lightblue",
     border="black")
```

Histograma do Score de Periculosidade



O histograma mostra uma distribuição aparentemente simétrica. Agora, calcula-se as principais medidas numéricas:

```
summary(dados$score_periculosidade)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   91.05  155.70  177.21  174.52  191.12  247.07
```

A média da amostra é 174.52, o que é um indício de que a média real pode ser, sim, superior a 170.

2. Teste de Hipótese Formal

Aplicando o Teste t de Student.

- H_0 (Hipótese Nula): Média ≤ 170
- H_1 (Hipótese Alternativa): Média > 170
- Alpha: 0.05

```
t.test(
  dados$score_periculosidade,
  mu = 170,
  alternative = "greater"
)
```

```
##
## One Sample t-test
##
## data: dados$score_periculosidade
## t = 2.4874, df = 199, p-value = 0.006845
## alternative hypothesis: true mean is greater than 170
## 95 percent confidence interval:
## 171.5172      Inf
## sample estimates:
## mean of x
## 174.5206
```

3. Conclusão da Questão 1

O teste retornou um **p-valor = 0.006845**.

Como o p-valor (0.0068) é **menor** que o nível de significância (0.05), **rejeita-se a Hipótese Nula**.

Resposta: Sim, existem evidências estatísticas suficientes para afirmar que o score médio de periculosidade é superior a 170 pontos. O intervalo de confiança de 95% reforça esta conclusão.


Questão 2:

Podemos afirmar que o tempo médio de prisão entre homens e mulheres é igual? Utilize um nível de significância de 5%. Caso os tempos médios sejam significativamente diferentes, apresente o intervalo de confiança de 95% para essa diferença.

1. Análise Exploratória de Dados

Para comparar os dois grupos (0 = Feminino, 1 = Masculino), usamos um boxplot.

```
# Boxplot comparativo
boxplot(tempo_preso ~ sexo, data = dados,
        main="Tempo de Prisão por Sexo",
        ylab="Tempo de Prisão (dias)",
        xlab="Sexo (0 = Feminino, 1 = Masculino)",
        col=c("pink", "lightblue"))
```



O gráfico mostra que a mediana (linha grossa) do grupo 1 (Masculino) é um pouco mais alta que a do grupo 0 (Feminino), mas as caixas se sobrepõem bastante, o que sugere que a diferença pode não ser significativa.

2. Teste de Hipótese Formal

Vamos agora realizar o Teste t formal para duas amostras independentes.

- H_0 (Hipótese Nula): As médias são iguais ($\mu_F = \mu_M$)
- H_1 (Hipótese Alternativa): As médias são diferentes ($\mu_F \neq \mu_M$)
- Alpha: 0.05

```
# Teste t para duas amostras (o padrão é 'alternative = "two.sided"')
t.test(tempo_preso ~ sexo, data = dados, alternative = "two.sided")
```

```
##
##  Welch Two Sample t-test
##
## data:  tempo_preso by sexo
## t = -1.2478, df = 113.72, p-value = 0.2147
## alternative hypothesis: true difference in means between group Masculino and group Feminino is not equal to 0
## 95 percent confidence interval:
##   -4.976204   1.130014
## sample estimates:
## mean in group Masculino  mean in group Feminino
##           59.25806           61.18116
```

3. Conclusão da Questão 2

O teste retornou um **p-valor = 0.2147**.

Como o p-valor (0.2147) é **MAIOR** que o nosso nível de significância (0.05), nós **falhamos em rejeitar a Hipótese Nula**.

Resposta: Não, não podemos afirmar que os tempos médios são iguais. Não há evidência estatística suficiente para rejeitar a hipótese de que o tempo médio de prisão é igual entre homens e mulheres. A pequena diferença vista no gráfico é provavelmente devida ao acaso.

Questão 3:

Existe correlação entre o tempo de prisão e o score de periculosidade? Utilize um nível de significância de 5% e apresente o valor do coeficiente de correlação.

1. Visualização da normalidade para ‘tempo_preso’


```
qq1 <- ggqqplot(dados$tempo_preso)
```

2. Visualização da normalidade para ‘score_periculosidade’

```
qq2 <- ggqqplot(dados$score_periculosidade)
```

3. Exibição conjunta

```
qq1 + qq2
```



4. Teste formal de Shapiro-Wilk para 'tempo_preso'

```
shapiro.test(x = dados$tempo_preso)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  dados$tempo_preso
## W = 0.99252, p-value = 0.4003
```

5. Teste formal de Shapiro-Wilk para 'score_periculosidade'

```
shapiro.test(x = dados$score_periculosidade)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  dados$score_periculosidade
## W = 0.99516, p-value = 0.7738
```


6. Interpretação:

- Tempo de Prisão: O p-valor (0.4003) é maior que o nível de significância de 0.05. Portanto, não rejeitamos a Hipótese Nula (H_0).

Concluimos que não há evidência estatística de que a variável `tempo_preso` se afaste da normalidade.


- Score de Periculosidade: O p-valor (0.7738) também é maior que 0.05. Não rejeitamos a H_0 , indicando que é razoável assumir que o `score_periculosidade` possui distribuição aproximadamente normal.

Como ambas as variáveis se aproximam da distribuição normal, o teste de correlação de *Pearson* é o procedimento estatístico adequado.

7. Definição do teste de correlação

7.1. Gráfico de dispersão para avaliar a relação visualmente

```
ggplot(data = dados,  
       mapping = aes(x = tempo_preso,  
                     y = score_periculosidade)) +  
  geom_point() +  
  labs(y = "Score de Periculosidade", x = "Tempo de Prisão (meses)") +  
  theme_minimal()
```



7.2. Estimativa pontual do coeficiente de correlação (r)

```
r_amostral <- cor(x = dados$tempo_preso,
                  y = dados$score_periculosidade,
                  use = "pairwise.complete.obs")
print(r_amostral)
```

```
## [1] 0.8037558
```

7.3. Teste de Correlação de Pearson (bilateral)

```
cor.test(x = dados$tempo_preso,
         y = dados$score_periculosidade,
         method = "pearson",
         alternative = "two.sided",
         conf.level = 0.95)
```

```
##
## Pearson's product-moment correlation
##
## data: dados$tempo_preso and dados$score_periculosidade
## t = 19.009, df = 198, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.7484808 0.8479398
## sample estimates:
##      cor
## 0.8037558
```

8. Conclusão da Questão 3

O valor do coeficiente de correlação de Pearson é de aproximadamente 0.804. O teste de hipóteses (H_0 : $P=0$) foi rejeitado, pois o p-valor ($<2.2e-16$) foi inferior ao nível de significância adotado ($\alpha=0.05$). A correlação é forte e positiva, indicando que um tempo de prisão mais longo está significativamente associado a um score de periculosidade mais elevado. Portanto,

Resposta: Sim, existe correlação estatisticamente entre tempo de prisão e o score de periculosidade

Questão 4: