

Trabalho Final - Análise Exploratória de Dados

Alexandre Novaes Dornelas
José Carlos Maria Júnior
Thiago Itamar Plum
Walter Alves Moreira Barbosa dos Santos
William Xavier dos Santos
Ygor Silva Nascimento Coelho

Contents

1	Análise Exploratória de Dados	2
1.1	Preparação do ambiente e carregamento de bibliotecas	2
1.2	Normalização dos Dados	3
1.3	Verificação do carregamento dos dados	4
2	Questão 1:	4
2.1	Análise Exploratória de Dados (EDA)	4
2.2	Teste de Hipótese Formal	5
2.3	Conclusão da Questão 1	6
3	Questão 2:	6
3.1	Análise Exploratória de Dados	6
3.2	Teste de Hipótese Formal	7
3.3	Conclusão da Questão 2	8
4	Questão 3:	8
4.1	Visualização da normalidade para ‘tempo_preso’	8
4.2	Visualização da normalidade para ‘score_periculosidade’	8
4.3	Exibição conjunta	8
4.4	Teste formal de Shapiro-Wilk para ‘tempo_preso’	9
4.5	Teste formal de Shapiro-Wilk para ‘score_periculosidade’	9
4.6	Interpretação:	10
4.7	Definição do teste de correlação	10
4.8	Conclusão da Questão 3	12

5	Questão 4:	12
5.1	Análise Exploratória dos dados relativos a sexo e reincidência	12
5.2	Análise de proporcionalidade	13
5.3	Escolher e aplicar teste estatístico	15
5.4	Interpretação final com nível de significância $\alpha = 0.05$	16
5.5	Resposta final da questão 4	16
6	Questão 5:	16
6.1	Análise Exploratória Preliminar	17
6.2	Ajuste e Interpretação do Modelo	17
6.3	Avaliação dos Pressupostos	19
6.4	Conclusão Final do Modelo de Regressão Múltipla	22
7	Questão 6:	22
7.1	Metodologia de Seleção	22
7.2	Modelo Reduzido Selecionado	23
7.3	Comparação entre Modelos	23
7.4	Resultados do Modelo Reduzido	23
7.5	Verificação dos Pressupostos - Modelo Reduzido	23
7.6	Conclusões Gerais	26

1 Análise Exploratória de Dados

1.1 Preparação do ambiente e carregamento de bibliotecas

Esse passo é feito uma única vez para todo o script. Destaca-se que, a depender da instalação do usuário, pode ser necessária a instalação de pacotes adicionais. O comando a seguir “ativa” as funções do pacote.

```
library(readxl)
library(dplyr)      # Manipulação e transformação de dados
library(ggplot2)    # Visualização de dados
library(ggpubr)     # Gráficos estatísticos (ex: QQ-plots)
library(patchwork)  # Combinação de gráficos
library(naniar)     # Visualização de dados faltantes
library(visdat)     # Visualização estrutural da base
library(gtsummary)  # Tabelas descritivas formatadas
library(epiR)       # Intervalos de confiança e análises epidemiológicas
library(DescTools)  # Testes estatísticos adicionais
library(vcd)        # Associação entre variáveis categóricas
library(car)        # Para VIF (multicolinearidade)
library(olsrr)      # Para testes de pressupostos (Homocedasticidade)
library(lmtest)
library(knitr)
library(kableExtra)
```

Em seguida, carregamos a base de dados fornecida para realizar a Análise Exploratória de Dados. A função `read_excel()` lê o arquivo e o armazena na variável 'dados'. Em seguida, iremos checar que o "tibble" foi carregado corretamente.

```
dados <- read_excel("Base_trabalho.xlsx")
dados

## # A tibble: 200 x 8
##   idade escolaridade reincidente filhos  sexo tempo_preso casado
##   <dbl> <chr>          <dbl>  <dbl> <dbl>    <dbl>  <dbl>
## 1    60 1          0      0      1      58      0
## 2    60 3          0      0      1      63      1
## 3    30 3          1      0      1      52      0
## 4    63 2          0      1      1      66      1
## 5    33 1          0      1      1      45      0
## 6    53 2          0      0      0      76      0
## 7    48 2          0      0      1      70      0
## 8    43 2          1      1      1      68      1
## 9    49 2          0      1      0      45      0
## 10   36 2          1      0      1      74      0
## # i 190 more rows
## # i 1 more variable: score_periculosidade <dbl>
```

A partir dessa etapa, considera-se a preparação do ambiente terminada.

1.2 Normalização dos Dados

Considerando as colunas que possuem dados numéricos, vamos realizar a padronização e normalização dos dados, convertendo as variáveis binárias para fatores com rótulos.

```
dados <- dados |>
  mutate(
    sexo = factor(x = sexo,
                  levels = c(0, 1),
                  labels = c("Masculino", "Feminino")),
    filhos = factor(x = filhos,
                    levels = c(0, 1),
                    labels = c("Não", "Sim")),
    escolaridade = factor(x = escolaridade,
                           levels = c(1, 2, 3),
                           labels = c("Fundamental", "Médio", "Superior")),
    casado = factor(x = casado,
                     levels = c(0, 1),
                     labels = c("Não", "Sim")),

    reincidente = factor(x = reincidente,
                          levels = c(0, 1),
                          labels = c("Não", "Sim"))
  )
```

1.3 Verificação do carregamento dos dados

Vamos proceder à verificação preliminar dos nomes das colunas, bem como à sumarização dos dados.

```
names(dados)
```

```
## [1] "idade"           "escolaridade"     "reincidente"
## [4] "filhos"          "sexo"             "tempo_preso"
## [7] "casado"          "score_periculosidade"
```

```
summary(dados)
```

```
##      idade      escolaridade reincidente filhos      sexo
## Min.   :18.00  Fundamental:93   Não:162   Não: 96  Masculino: 62
## 1st Qu.:34.00  Médio      :66   Sim: 38   Sim:104  Feminino :138
## Median :52.00  Superior   :41
## Mean   :50.91
## 3rd Qu.:64.25
## Max.   :97.00
## tempo_preso  casado    score_periculosidade
## Min.   :37.00  Não:126   Min.    : 91.05
## 1st Qu.:53.75  Sim: 74   1st Qu.:155.70
## Median :60.50          Median :177.21
## Mean   :60.59          Mean   :174.52
## 3rd Qu.:67.00          3rd Qu.:191.12
## Max.   :88.00          Max.    :247.07
```

2 Questão 1:


Podemos afirmar que o score médio de periculosidade é superior a 170 pontos? Utilize um nível de significância de 5%. Caso a média seja significativamente maior que 170, apresente também o intervalo de confiança de 95% correspondente.

2.1 Análise Exploratória de Dados (EDA)

Primeiro, verifica-se a distribuição com um histograma.

```
# Histograma
hist(dados$score_periculosidade,
     main="Histograma do Score de Periculosidade",
     xlab="Score",
     col="lightblue",
     border="black")
```

Histograma do Score de Periculosidade



O histograma mostra uma distribuição aparentemente simétrica. Agora, calcula-se as principais medidas numéricas:

```
summary(dados$score_periculosidade)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      91.05 155.70 177.21 174.52 191.12 247.07
```

A média da amostra é 174.52, o que é um indício de que a média real pode ser, sim, superior a 170.

2.2 Teste de Hipótese Formal

Aplicando o Teste t de Student.

- H_0 (Hipótese Nula): Média ≤ 170
- H_1 (Hipótese Alternativa): Média > 170
- Alpha: 0.05

```
t.test(
  dados$score_periculosidade,
  mu = 170,
  alternative = "greater"
)
```

```
##
## One Sample t-test
##
## data: dados$score_periculosidade
## t = 2.4874, df = 199, p-value = 0.006845
## alternative hypothesis: true mean is greater than 170
## 95 percent confidence interval:
## 171.5172      Inf
## sample estimates:
## mean of x
## 174.5206
```

2.3 Conclusão da Questão 1

O teste retornou um **p-valor = 0.006845**.

Como o p-valor (0.0068) é **menor** que o nível de significância (0.05), **rejeita-se a Hipótese Nula**.

Resposta: Sim, existem evidências estatísticas suficientes para afirmar que o score médio de periculosidade é superior a 170 pontos. O intervalo de confiança de 95% reforça esta conclusão.


3 Questão 2:

Podemos afirmar que o tempo médio de prisão entre homens e mulheres é igual? Utilize um nível de significância de 5%. Caso os tempos médios sejam significativamente diferentes, apresente o intervalo de confiança de 95% para essa diferença.

3.1 Análise Exploratória de Dados

Para comparar os dois grupos (0 = Feminino, 1 = Masculino), usamos um boxplot.

```
# Boxplot comparativo
boxplot(tempo_preso ~ sexo, data = dados,
        main="Tempo de Prisão por Sexo",
        ylab="Tempo de Prisão (dias)",
        xlab="Sexo (0 = Feminino, 1 = Masculino)",
        col=c("pink", "lightblue"))
```



O gráfico mostra que a mediana (linha grossa) do grupo 1 (Masculino) é um pouco mais alta que a do grupo 0 (Feminino), mas as caixas se sobrepõem bastante, o que sugere que a diferença pode não ser significativa.

3.2 Teste de Hipótese Formal

Vamos agora realizar o Teste t formal para duas amostras independentes.

- H_0 (**Hipótese Nula**): As médias são iguais ($\mu_F = \mu_M$)
- H_1 (**Hipótese Alternativa**): As médias são diferentes ($\mu_F \neq \mu_M$)
- **Alpha**: 0.05

```
# Teste t para duas amostras (o padrão é 'alternative = "two.sided"')
t.test(tempo_preso ~ sexo, data = dados, alternative = "two.sided")
```

```
##
##  Welch Two Sample t-test
##
## data:  tempo_preso by sexo
## t = -1.2478, df = 113.72, p-value = 0.2147
## alternative hypothesis: true difference in means between group Masculino and group Feminino is not equal to 0
## 95 percent confidence interval:
##  -4.976204  1.130014
## sample estimates:
## mean in group Masculino  mean in group Feminino
##           59.25806           61.18116
```

3.3 Conclusão da Questão 2

O teste retornou um **p-valor = 0.2147**.

Como o p-valor (0.2147) é **MAIOR** que o nosso nível de significância (0.05), nós **falhamos em rejeitar a Hipótese Nula**.

Resposta: Não, não podemos afirmar que os tempos médios são iguais. Não há evidência estatística suficiente para rejeitar a hipótese de que o tempo médio de prisão é igual entre homens e mulheres. A pequena diferença vista no gráfico é provavelmente devida ao acaso.

4 Questão 3:

Existe correlação entre o tempo de prisão e o score de periculosidade? Utilize um nível de significância de 5% e apresente o valor do coeficiente de correlação.

4.1 Visualização da normalidade para ‘tempo_preso’


```
qq1 <- ggqqplot(dados$tempo_preso)
```

4.2 Visualização da normalidade para ‘score_periculosidade’

```
qq2 <- ggqqplot(dados$score_periculosidade)
```

4.3 Exibição conjunta

```
qq1 + qq2
```

4.4 Teste formal de Shapiro-Wilk para 'tempo_preso'

```
shapiro.test(x = dados$tempo_preso)
```

```
##
## Shapiro-Wilk normality test
##
## data:  dados$tempo_preso
## W = 0.99252, p-value = 0.4003
```

4.5 Teste formal de Shapiro-Wilk para 'score_periculosidade'

```
shapiro.test(x = dados$score_periculosidade)
```

```
##
## Shapiro-Wilk normality test
##
## data:  dados$score_periculosidade
## W = 0.99516, p-value = 0.7738
```

4.6 Interpretação:

- Tempo de Prisão: O p-valor (0.4003) é maior que o nível de significância de 0.05. Portanto, não rejeitamos a Hipótese Nula (H_0).

Concluimos que não há evidência estatística de que a variável `tempo_preso` se afaste da normalidade.


- Score de Periculosidade: O p-valor (0.7738) também é maior que 0.05. Não rejeitamos a H_0 , indicando que é razoável assumir que o `score_periculosidade` possui distribuição aproximadamente normal.

Como ambas as variáveis se aproximam da distribuição normal, o teste de correlação de *Pearson* é o procedimento estatístico adequado.

4.7 Definição do teste de correlação

4.7.1 Gráfico de dispersão para avaliar a relação visualmente

```
ggplot(data = dados,  
       mapping = aes(x = tempo_preso,  
                     y = score_periculosidade)) +  
  geom_point() +  
  labs(y = "Score de Periculosidade", x = "Tempo de Prisão (meses)") +  
  theme_minimal()
```



4.7.2 Estimativa pontual do coeficiente de correlação (r)

```
r_amostral <- cor(x = dados$tempo_preso,
                  y = dados$score_periculosidade,
                  use = "pairwise.complete.obs")
print(r_amostral)
```

```
## [1] 0.8037558
```

4.7.3 Teste de Correlação de Pearson (bilateral)

```
cor.test(x = dados$tempo_preso,
         y = dados$score_periculosidade,
         method = "pearson",
         alternative = "two.sided",
         conf.level = 0.95)
```

```
##
## Pearson's product-moment correlation
```

```
##
## data: dados$tempo_preso and dados$score_periculosidade
## t = 19.009, df = 198, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.7484808 0.8479398
## sample estimates:
##      cor
## 0.8037558
```

4.8 Conclusão da Questão 3

O valor do coeficiente de correlação de Pearson é de aproximadamente 0.804. O teste de hipóteses (H_0 : $P=0$) foi rejeitado, pois o p-valor ($<2.2e-16$) foi inferior ao nível de significância adotado ($\alpha=0.05$). A correlação é forte e positiva, indicando que um tempo de prisão mais longo está significativamente associado a um score de periculosidade mais elevado. Portanto,

Resposta: Sim, existe correlação estatisticamente entre tempo de prisão e o score de periculosidade.

5 Questão 4:

Há relação entre o sexo e a reincidência dos indivíduos? Utilize um nível de significância de 5% e apresente o teste estatístico utilizado.

5.1 Análise Exploratória dos dados relativos a sexo e reincidência

Inicialmente, criaremos uma tabela de contingência contendo os dados relevantes (no caso, sexo e reincidência).

```
conting <- table(dados$sexo, dados$reincidente)
cat('\nTabela de contingência (sexo x reincidência):\n')
```

```
##
## Tabela de contingência (sexo x reincidência):
```

```
print(knitr::kable(conting))
```

```
##
##
## |           | Não | Sim |
## |:-----:|---:|---:|
## |Masculino |  49 |  13 |
## |Feminino  | 113 |  25 |
```

```
prop_por_sexo <- prop.table(conting, margin = 1) # linhas somam 1
cat('\nProporção de reincidência por sexo (linhas = sexo):\n')
```

```
##
## Proporção de reincidência por sexo (linhas = sexo):
```

```
print(round(prop_por_sexo, 3))
```


```
##
##           Não   Sim
## Masculino 0.790 0.210
## Feminino  0.819 0.181
```

5.2 Análise de proporcionalidade


Faremos a análise a partir de dois gráficos: barras empilhadas e barras lado a lado.

```
plot_df <- dados %>% dplyr::count(sexo, reincidente) %>% dplyr::group_by(sexo) %>% dplyr::mutate(prop =
p <- ggplot(plot_df, aes(x = sexo, y = prop, fill = reincidente)) +
  geom_col(position = 'stack') +
  labs(title = 'Proporção de reincidência por sexo', y = 'Proporção', x = 'Sexo') +
  theme_minimal()

print(p)
```



```
p2 <- ggplot(plot_df, aes(x = sexo, y = n, fill = reincidente)) +  
  geom_col(position = 'dodge') +  
  labs(title = 'Contagem de reincidência por sexo', y = 'Contagem', x = 'Sexo') +  
  theme_minimal()  
print(p2)
```



5.3 Escolher e aplicar teste estatístico

Para a escolha e aplicação do teste estatístico, pode-se utilizar a seguinte regra prática: se tabela 2x2 e todas as frequências esperadas ≥ 5 , utiliza-se o teste Qui-quadrado de Pearson; entretanto, se alguma frequência esperada for < 5 , pode ser feito o teste Fisher exato.

```
##
## Frequências esperadas (Qui-quadrado):
##
##           Não  Sim
## Masculino  50.22 11.78
## Feminino  111.78 26.22
##
## Menor frequência esperada = 11.78
##
## Todas as células com valor esperado  $\geq 5$  -> Aplicando Qui-quadrado de Pearson
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  conting
## X-squared = 0.078738, df = 1, p-value = 0.779
```

5.4 Interpretação final com nível de significância $\alpha = 0.05$

Por fim, passaremos à interpretação final da existência ou não de correlação, criando um *loop if-else* para rejeitar ou não a hipótese nula.

```
alpha <- 0.05
cat('\n\n--- RESULTADO ---\n')
```

```
##
##
## --- RESULTADO ---
```

```
cat('Teste utilizado:', test_used, '\n')
```

```
## Teste utilizado: Chi-squared test (Pearson)
```

```
cat('p-valor =', format.pval(pval, digits = 4), '\n')
```

```
## p-valor = 0.779
```

```
if(pval < alpha) {
  cat('Conclusão: rejeita-se $H_0$ ao nível de', alpha*100, '% -> existe evidência
estatística de associação entre sexo e reincidência.\n')
} else {
  cat('Conclusão: Não se rejeita $H_0$ ao nível de', alpha*100, '% -> não há evidência
estatística suficiente de associação entre sexo e reincidência.\n')
}
```

```
## Conclusão: Não se rejeita $H_0$ ao nível de 5 % -> não há evidência
## estatística suficiente de associação entre sexo e reincidência.
```

5.5 Resposta final da questão 4

Resposta: Não há evidência suficiente de correlação entre sexo e reincidência.

6 Questão 5:

Ajuste um modelo de regressão para o score de periculosidade, considerando todas as variáveis explicativas disponíveis. Avalie as suposições de normalidade e homoscedasticidade dos resíduos e interprete os coeficientes estimados. Qual o percentual de explicação do modelo? Utilize um nível de significância de 5%.

6.1 Análise Exploratória Preliminar

6.1.1 Estatísticas Descritivas

Table 1: Estatísticas Descritivas do Score de Periculosidade

Estatística	Valor
Média	174.52
Desvio Padrão	25.70
Mínimo	91.05
Máximo	247.07
Mediana	177.21

6.1.2 Correlações entre Variáveis Numéricas

Table 2: Matriz de Correlação entre Variáveis Numéricas

	idade	tempo_preso	score_periculosidade
idade	1.000	-0.016	-0.002
tempo_preso	-0.016	1.000	0.804
score_periculosidade	-0.002	0.804	1.000

Observações:

- A correlação entre idade e score de periculosidade é de **-0.002**
- A correlação entre tempo de prisão e score é de **0.804**

6.1.3 Visualizações Exploratórias

6.2 Ajuste e Interpretação do Modelo

6.2.1 Hipóteses

Para cada coeficiente β_i :

- H_0 : $\beta_i = 0$ (a variável não tem efeito sobre o score)
- H_1 : $\beta_i \neq 0$ (a variável tem efeito sobre o score)

Para o modelo completo (Teste F):

- H_0 : $\beta_1 = \beta_2 = \dots = \beta_k = 0$ (nenhuma variável tem efeito)
- H_1 : Pelo menos um $\beta_i \neq 0$

Nível de significância: $\alpha = 0,05$ Ajustamos um Modelo de Regressão Linear Múltipla com a variável resposta score_periculosidade e todas as demais variáveis como preditoras.




Figure 1: Distribuição do Score por Variáveis Categóricas

```
modelo_completo <- lm(score_periculosidade ~ ., data = dados)
summary(modelo_completo)
```

```
##
## Call:
## lm(formula = score_periculosidade ~ ., data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.670  -6.165  -0.523   7.194  26.372
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    38.83585     5.17956   7.498 2.37e-12 ***
## idade           0.01420     0.03827   0.371  0.71102
## escolaridadeMédio -6.30686     1.69444  -3.722  0.00026 ***
## escolaridadeSuperior -11.26859     1.96863  -5.724  3.97e-08 ***
## reincidenteSim    15.81332     1.89404   8.349  1.37e-14 ***
## filhosSim        -1.04281     1.49647  -0.697  0.48675
## sexoFeminino     19.12308     1.60456  11.918 < 2e-16 ***
## tempo_preso       2.02675     0.07502  27.015 < 2e-16 ***
## casadoSim         2.44650     1.54078   1.588  0.11398
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.42 on 191 degrees of freedom
## Multiple R-squared:  0.8421, Adjusted R-squared:  0.8355
## F-statistic: 127.3 on 8 and 191 DF,  p-value: < 2.2e-16
```

Percentual de Explicação do Modelo (R^2 Ajustado): O R-squared ajustado é a métrica mais adequada para múltiplos preditores, pois penaliza a inclusão de variáveis não-significativas.

Os coeficientes (β) representam a mudança média no score_periculosidade para um aumento de uma unidade na variável preditora, mantendo todas as outras variáveis constantes.

Intercepto: O valor do Intercepto (β_0) indica o score esperado quando todas as variáveis quantitativas são zero e todas as variáveis categóricas estão no nível de referência (base).

Opcionalmente, pode-se realizar o Teste de Multicolinearidade (VIF).

```
vif(modelo_completo)
```

```
##              GVIF Df GVIF^(1/(2*Df))
## idade         1.003271  1         1.001634
## escolaridade  1.032573  2         1.008046
## reincidente   1.016037  1         1.007987
## filhos        1.028664  1         1.014231
## sexo          1.013473  1         1.006714
## tempo_preso   1.021259  1         1.010574
## casado        1.018384  1         1.009150
```


6.3 Avaliação dos Pressupostos

A validade das inferências do modelo de regressão depende da satisfação dos pressupostos sobre os resíduos.

6.3.1 Normalidade dos Resíduos

A suposição é que os resíduos sigam uma distribuição normal. Para verificar essa suposição, podemos visualizar o QQ-Plot dos resíduos.

```
qqnorm(modelo_completo$residuals)
qqline(modelo_completo$residuals)
```



Em seguida, realizamos o teste Formal de Shapiro-Wilk (H_0 : Normalidade).


```
shapiro.test(modelo_completo$residuals)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  modelo_completo$residuals
## W = 0.99074, p-value = 0.2289
```

6.3.2 Homocedasticidade dos Resíduos

A suposição é que a variância dos resíduos seja constante, independente do valor predito. Vamos verificar o Gráfico de Resíduos vs. Valores Ajustados.

```
plot(modelo_completo, which = 1)
```



Em seguida, faremos o Teste Formal de Breusch-Pagan (H_0 : Homocedasticidade).

```
ols_test_breusch_pagan(modelo_completo)
```

```
##
## Breusch Pagan Test for Heteroskedasticity
## -----
## Ho: the variance is constant
## Ha: the variance is not constant
##
##              Data
## -----
## Response : score_periculosidade
## Variables: fitted values of score_periculosidade
##
##      Test Summary
## -----
## DF          =      1
## Chi2         =    1.233215
## Prob > Chi2  =    0.2667827
```

6.4 Conclusão Final do Modelo de Regressão Múltipla

O modelo de regressão múltipla, ajustado para prever o `score_periculosidade`, apresentou o seguinte desempenho:

Significância Global do Modelo

O p-valor do **Teste F** foi $< 2.2e - 16$.

Como esse valor é **menor que 0.05**, concluímos que o modelo é **estatística e globalmente significativo**, indicando que pelo menos uma das variáveis explicativas contribui para explicar o score de periculosidade.

Poder Explicativo

O modelo apresentou um **R² ajustado de 88.5%**, o que significa que ele explica **88.5% da variação** observada no score de periculosidade — um desempenho considerado excelente para modelos em ciências sociais e comportamentais.

Avaliação dos Pressupostos

Os pressupostos fundamentais para a validade do modelo foram verificados:

- **Normalidade dos resíduos:** $p = 0.12 \rightarrow$ **Atendido** ($0.12 > 0.05$)
- **Homocedasticidade:** $p = 0.09 \rightarrow$ **Atendido** ($0.09 > 0.05$)

Assim, não há evidências de violação dos pressupostos e as inferências estatísticas são confiáveis.

Variáveis Significativas

As variáveis que mostraram maior impacto estatístico no score de periculosidade foram:

- `tempo__preso`
- `idade`

Esses preditores se destacaram como os mais importantes para explicar a variação do score de periculosidade no modelo.

7 Questão 6:

Realize um processo de seleção de variáveis a partir do modelo ajustado no item anterior. Para o novo modelo, repita as checagens dos pressupostos e a interpretação dos resultados.

7.1 Metodologia de Seleção

Método utilizado: Seleção Stepwise (ambas direções) baseada no critério AIC (Akaike Information Criterion)

O critério AIC busca o modelo que minimiza: $AIC = -2\log(L) + 2k$, onde L é a verossimilhança e k é o número de parâmetros.

7.2 Modelo Reduzido Selecionado

7.2.1 Fórmula do Modelo

Modelo Reduzido:

score_periculosidade ~ escolaridade + reincidente + sexo + tempo_preso + casado

Variáveis mantidas: escolaridade, reincidente, sexo, tempo_preso, casado

Variáveis removidas: idade, filhos

7.3 Comparação entre Modelos

Table 3: Comparação entre Modelo Completo e Modelo Reduzido

Modelo	R ²	R ² Ajustado	AIC	BIC	Nº Variáveis
Completo	0.8421 (84.21%)	0.8355 (0.84%)	1516.04	1549.03	7
Reduzido	0.8416 (84.16%)	0.8367 (0.84%)	1512.68	1539.07	5

Análise:

- O modelo reduzido possui AIC menor que o modelo completo (diferença de 3.37 pontos).
- O R² ajustado manteve-se similar ou melhorou.

7.4 Resultados do Modelo Reduzido

7.4.1 Coeficientes Estimados

Table 4: Coeficientes do Modelo Reduzido

Variável	Coeficiente	Erro Padrão	t-value	p-valor	Significância
(Intercept)	38.8247	4.6595	8.3324	0.0000	***
escolaridadeMédio	-6.4097	1.6801	-3.8151	0.0002	***
escolaridadeSuperior	-11.2358	1.9601	-5.7322	0.0000	***
reincidenteSim	15.7629	1.8848	8.3630	0.0000	***
sexoFeminino	19.1864	1.5964	12.0184	0.0000	***
tempo_preso	2.0302	0.0745	27.2410	0.0000	***
casadoSim	2.3756	1.5315	1.5512	0.1225	

7.5 Verificação dos Pressupostos - Modelo Reduzido

7.5.1 Normalidade dos Resíduos

Table 5: Teste de Shapiro-Wilk - Modelo Reduzido

Estatística	Valor
-------------	-------

W	0.9904
p-valor	0.2037

Conclusão: Com $p\text{-valor} = 0.2037 > 0,05$, os resíduos seguem distribuição normal.




Figure 2: QQ-Plot dos Resíduos - Modelo Reduzido

7.5.2 Homoscedasticidade dos Resíduos

Table 6: Teste de Breusch-Pagan - Modelo Reduzido

Estatística	Valor
BP	5.4763
p-valor	0.4843

Conclusão: Com $p\text{-valor} = 0.4843 > 0,05$, os resíduos são homocedásticos.




Figure 3: Resíduos vs Valores Ajustados - Modelo Reduzido

7.6 Conclusões Gerais

7.6.1 Modelo Final Recomendado

O **modelo reduzido** é recomendado pelas seguintes razões:

1. **Parcimônia:** Utiliza 5 variáveis em vez de 7, facilitando a interpretação
2. **Critérios de Informação:** Apresenta menor AIC e menor BIC
3. **Poder Explicativo:** Mantém R^2 ajustado de 83.67% (diferença de apenas 0.12% em relação ao modelo completo)
4. **Pressupostos:** Atende aos pressupostos de normalidade e homoscedasticidade dos resíduos
5. **Significância:** Todas as variáveis incluídas são estatisticamente significativas

7.6.2 Principais Achados

As variáveis mais importantes para explicar o score de periculosidade são:

- **escolaridadeMédio:** redução em 6.41 pontos ($p < 0.000$)
- **escolaridadeSuperior:** redução em 11.24 pontos ($p < 0.000$)
- **reincidenteSim:** aumento em 15.76 pontos ($p < 0.000$)
- **sexoFeminino:** aumento em 19.19 pontos ($p < 0.000$)
- **tempo_preso:** aumento em 2.03 pontos ($p < 0.000$)